Теория параллелизма

Отчет

Решение уравнения теплопроводности

Выполнил: Золотых Игорь, гр. 22933

Цель: реализовать решение уравнение теплопроводности (разностная схема – пятиточечный шаблон) в двумерной области на равномерных сетках (128^2, 256^2, 512^2, 1024^2).

Используемый компилятор: pgcc/pgc++ c ключами:"-acc", "-Minfo=all".

Используемый профилировщик: Nsight systems

Замеры времени работы призводили с помощью библиотеки <chrono>.

Выполнение на CPU


CPU- onecore

Размер сетки	Время выполнения(с)	Кол-во итераций							
128x128	0.46	1e-6	31000						
256x256	6.9	1e-6	103000						
512x512	96.27	1e-6	340000						

CPU-multicore

Размер сетки	Время выполнения(с)	Кол-во итераций	
128x128	0.32	1e-6	31000
256x256	1.58	1e-6	103000
512x512	17.28	1e-6	340000
1024x1024	168.26	1e-6	1067000

Диаграммы



Выполнение на GPU

Этапы оптимизации на сетке 512х512

Версия	Время	Точность	Максимальное	Комментарии
	выполнения(с)		количество	
			итераций	
1	764	1e-6	1 000 000	Понадобилось 340тыс. итераций
				для достижения заданной
				точности, использовались, очень
				много времени тратится на обмен
				данными между устройствами.
2	4.03	1e-6	1 000 000	Оптимизированы циклы и
				копирование данных,
				количество итераций то же.

В **первой версии** явно видно, что очень много времени(почти все!!!, +-97%) тратится на копирование данных с CPU на GPU и обратно. На работу самой программы было затрачено от всего времени. Нужно оптимизировать обмен данными. Так же не были оптимизированы циклы, это стоит исправить.



Зеленое – копирование с CPU на GPU, красное – наоборот, синее – операции.

Во **второй версии** были убраны лишние копирования данных, теперь это делается гораздо меньше раз, седовательно занимает в разы меньше времени. Так же были оптимизированы циклы. Были использованы атрибуты из **OpenACC** <u>independent</u> и <u>collapse</u>.

Independent нужен для того, чтобы сделать итерации цикла независимыми друг от друга.

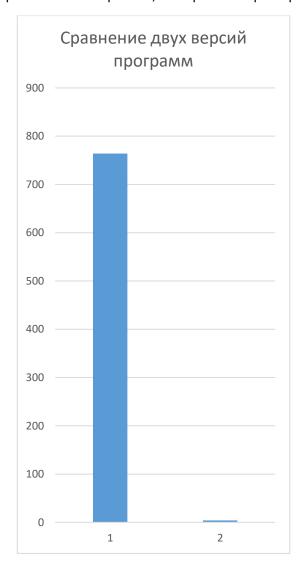
Collapse в свою очередь нужен для того, чтобы «слить» два цикла в один. Это позволяет распределить итерации более эффективно.

Все эти манипуляции дали очень значительный прирост в производительности.



0s •		+933	7ms	+93	33,75ms	-	+93	3,8ms	- 4	933,8	Sms	. 4	933,911	200	- 45	933,9	5ms		+934m	mi		934	05mi
 CUDA HW (0000:89 00:0 - Testa V 	kernel		1		4		V							-		1	B	H	A			-	ž
 99,7% Kernels 														0									I
+ 99,7%_9main2_cpp_main_10;														0									П
+ 0,2% _9main2_cpp_main_111,																							
+ 0,1%_9main2_cpp_main_111_																							
 + 0,3% Memory 			- 1		1	ā																	
27,6% Memset																							
31,2% H1oD memcpy					ш																		
41,2% DtoH memcpy																							
- Threads (4)																							
→ [79878] gpu2																							
CUDA API		01	80		CH.	10	u)c	u. I				-911	ein?	E.	00	u.	cu.	Qu.	cu.	1 9	91	0.,	
Profiler overhead																							
3 threads hidden+																							
3 threads hidden — +																							

Диаграмма оптимизации (по горизонтали номер этапа; по вертикали время работы)



Размер матрицы	Время выполнения	Точность	Кол-во итераций
128x128	0.32	1e-6	31000
256x256	1.42	1e-6	103000
512x512	4.03	1e-6	340000
1024x1024	37.95	1e-6	1067000

Диаграммы сравнения времени работы CPU-one, CPU-multi, GPU(оптимизированный вариант) для разных размеров сеток



Вывод

После написания нескольких кодов, которые работают по-разному, можно сказать, что на маленьких матрицах достаточно многопоточной реализации на CPU, но если матрицы большие, то гораздо производительнее оказывается GPU, особенно если правильно управлять операциями с паматью.